

hw 6 solution

Statistical Computing, Jieun Shin

Autumn 2021

문제 1.

1. $h(x) = x/(2^x - 1)$ 라고 할 때, 참 값 $I = \mathbb{E}[h(X)]$ 을 추정하는 방법 중 대조변수법을 이용한 추정량 \hat{I}_2 을 다음의 과정에 따라 정의할 수 있다.
 - (1) 먼저 $U_1, \dots, U_n \sim U(0, 1)$ 을 생성한다.
 - (2) 역변환법을 통해 $N(0, 1)$ 을 따르는 정규난수 X 를 생성한다. 정규난수는 $X = (F_X^{-1}(U_1), \dots, F_X^{-1}(U_n))$ 와 $X' = (F_X^{-1}(1 - U_1), \dots, F_X^{-1}(1 - U_n))$ 을 생성한다. 단, 이 문제의 경우 $X' = (1 - X_1, \dots, 1 - X_n)$ 와 동일하다.
 - (3) $N = 2n$ 이라 하면 대조변수법을 사용한 추정량은 다음과 같이 표현된다.

$$\hat{I}_2 = \frac{1}{N} \sum_{i=1}^{N/2} [h(X_i) + h(X'_i)]$$

2. \hat{I}_1 와 \hat{I}_2 의 분산은 다음과 같이 구할 수 있다.

$$\begin{aligned} \text{Var}(\hat{I}_1) &= \text{Var}\left(\frac{1}{N} \sum_{i=1}^N h(X_i)\right) = \frac{1}{N} \text{Var}(h(X_i)), \\ \text{Var}(\hat{I}_2) &= \text{Var}\left(\frac{1}{N} \sum_{i=1}^{N/2} [h(X_i) + h(X'_i)]\right) = \frac{1}{2N} [\text{Var}(h(X_i)) + \text{Var}(h(X'_i)) + 2\text{Cov}(h(X_i), h(X'_i))] \end{aligned}$$

결과를 보면 두 추정량은 1.5로 비슷한 값을 가지고 분산은 대조변수법의 분산이 더 작으며, 대조변수법에서 분산 감소를 비율이 약 95%임을 확인하였다.

```
set.seed(123)
N = 10000
n = N / 2

h = function(x) x / (2^x - 1)

# 표본평균 몬테칼로 추정량
X = rnorm(N)
h1 = h(X)
mean1 = mean(h1) # 추정치
var1 = var(h1) / N # 추정치의 분산

mean1; var1

## [1] 1.500168
## [1] 2.552766e-05
```

```

# 대조변수법을 이용한 추정량
X1 = rnorm(n)
X2 = -X1
X = c(X1, X2)

mean2 = mean(h(X)) # 추정치
var2 = ( var(h(X1)) + var(h(X2)) + 2 * cov(h(X1), h(X2)) ) / (2 * N) # 추정치의 분산

mean2; var2

## [1] 1.499257
## [1] 1.196732e-06

# 분산 감소 비율 비교
( var1 - var2 ) / var1

## [1] 0.9531202

```

문제 2.

1. $I = \int_0^{\pi/2} \cos x \, dx$ 을 적중법과 표본평균 몬테칼로 적분법으로 추정하고자 한다. 먼저 표본평균 몬테칼로 적분법은 다음의 과정을 따른다.

(1) 균일분포의 범위를 $[a, b]$ 라고 할 때, $a = 0, b = \frac{1}{\pi}$ 로 지정한 후 $U(0, \frac{\pi}{2})$ 에서 x_1, \dots, x_N 을 생성한다.

(2) 추정값 $\hat{I}_M = (b - a) \frac{1}{N} \sum_{i=1}^N g(x_i) = \frac{\pi}{2} \frac{1}{N} \sum_{i=1}^N \cos x_i$ 을 계산한다.

```

set.seed(123)
N = 10000
a = 0; b = pi/2; c = 1

# 표본평균 몬테칼로 적분법
x = runif(N, a, b)
(b - a) * mean( cos(x) )

```

```
## [1] 1.005431
```

적중법은 다음의 과정을 따른다.

(1) X 좌표에 해당하는 N 개의 값 x_1, \dots, x_N 을 $U(0, \frac{\pi}{2})$ 에서 생성하고, Y 좌표에 해당하는 N 개의 값 y_1, \dots, y_N 를 $U(0, 1)$ 에서 생성한다.

(2) 추정값 $\hat{I}_H = c(b - a)\hat{p} = \frac{\pi}{2} \frac{1}{N} \sum_{i=1}^N I(y_i \leq g(x_i))$ 을 계산한다. 여기서 \hat{p} 는 전체 난수발생 갯수 중 $g(x_i)$ 아래에 들어간 난수의 갯수이다.

```

# 적중법
x = runif(N, a, b)
y = runif(N, 0, c)
p = mean( y <= cos(x) )

c * (b - a) * p # 추정값

```

```
## [1] 0.9998119
```

결과를 보면 표본평균 몬테칼로 적분법과 적중법 모두 1 근처의 값으로 I 를 추정하였다.

표본 크기는

$$P(|\hat{I} - I| < \epsilon) > 1 - \alpha$$

$$\geq 1 - \frac{Var(\hat{I})}{\epsilon^2} \geq 1 - \alpha \quad \because \text{chebyshev inequality}$$

을 만족하도록 하며, 표본평균 몬테칼로 적분법에서는

$$1 - \frac{Var(\hat{I})}{\epsilon} \geq 1 - \alpha$$

$$\frac{Var(\hat{I})}{\epsilon^2} \leq \alpha$$

$$\frac{(b-a)^2}{N} \left(\int_a^b g(x)^2 dx - I^2 \right) \leq \alpha \epsilon^2$$

$$\frac{(b-a)^2}{\alpha \epsilon^2} \left(\int_a^b g(x)^2 dx - I^2 \right) \leq N$$

을 만족하는 N 을 구하고, 적중법에서는

$$1 - \frac{Var(\hat{I})}{\epsilon} \geq 1 - \alpha$$

$$\frac{Var(\hat{I})}{\epsilon} \leq \alpha$$

$$c^2(b-a)^2 \frac{p(1-p)}{N} \leq \alpha \epsilon^2$$

$$\frac{c^2(b-a)^2}{4\alpha \epsilon^2} \leq N$$

을 만족하는 N 을 구한다.

결과를 보면 몬테칼로 적분법에서 필요한 표본 크기는 약 107,632,281개, 적중법에서 필요한 표본 크기는 약 61,685,028개로 적중법에서 필요한 표본크기가 더 적다.

```
# 표본 크기 구하기
alpha = 0.01
e = 10^(-3)

g = function(x) cos(x)
g1 = function(x) x * cos(x)          # g1(X) = x cos(x)
g2 = function(x) x * cos(x)^2        # g2(X) = x cos^2(x)

I = integrate(g, a, b)$value ; I # I의 이론적인 값 = 1

## [1] 1
I1 = integrate(g1, a, b)$value ; I1 # E[g(X)]의 이론적인 값 = 0.5708

## [1] 0.5707963
I2 = integrate(g2, a, b)$value ; I2 # E[g(X)^2]의 이론적인 값 = 0.3669

## [1] 0.3668503

# 표본평균 몬테칼로 적분법의 표본크기
(b - a)^2 * ( I1 - I2^2 ) / ( alpha * e^2 )
```

```
## [1] 107632281
```

```
# 적응법의 표본크기
```

```
( (c * (b - a)^2) ) / (4 * alpha * e^2)
```

```
## [1] 61685028
```

2. $f_1(x)$ 을 주함수로 한 주표본기법 추정치를 \hat{I}_{f1} , $f_2(x)$ 을 주함수로 한 주표본기법 추정치를 \hat{I}_{f2} 라 하자. 다음 과정에 따라 \hat{I}_{f1} 와 \hat{I}_{f2} 을 추정할 수 있다.

(1) $U(0, \frac{\pi}{2})$ 로부터 x_1, \dots, x_N 을 생성한다.

(2) 각 추정치 $\hat{I}_{f1} = \frac{1}{N} \sum_{i=1}^N \frac{g(x_i)}{f_1(x_i)} = \frac{\pi}{2} \frac{1}{N} \sum_{i=1}^N \cos x_i$ 와 $\hat{I}_{f2} = \frac{1}{N} \sum_{i=1}^N \frac{g(x_i)}{f_2(x_i)} = \frac{1}{N} \sum_{i=1}^N \frac{\cos x_i}{\frac{4}{\pi}(1 - \frac{2}{\pi}x_i)}$ 를 계산하여 구한다.

주표본 추정치에 대한 분산은 $\text{Var}(\hat{I}) = \frac{1}{N} \left(\int_a^b \frac{g^2(x)}{f_1(x)} dx - I^2 \right)$ 이므로 \hat{I}_{f1} 의 분산은 $\text{Var}(\hat{I}_{f1}) = \frac{1}{N} \left(\int_0^{\frac{\pi}{2}} \frac{\cos^2 x}{\frac{4}{\pi}} dx - I^2 \right)$ 으로 계산할 수 있다.

결과를 보면 주함수가 f_1 일 때와 주함수가 f_2 일 때 모두 주표본 추정치는 약 1이며, 분산을 비교하면 f_1 의 분산이 f_2 의 분산보다 더 작게 나타났다.

```
g = function(x) cos(x)
f1 = function(x) (2 / pi)
f2 = function(x) (1 - (2 / pi) * x) * (4 / pi)

gf1 = function(x) cos(x)^2 * (pi / 2)
gf2 = function(x) cos(x)^2 / ( (1 - (2 / pi) * x) * (pi / 4) )

set.seed(123)
u = runif(N, a, b)

# 주함수를 f1으로 했을 때의 주표본 추정치와 분산
mean( g(u) / f1(u) ) ; (integrate(gf1, a, b)$value - I^2) / N
```

```
## [1] 1.005431
```

```
## [1] 2.337006e-05
```

```
# 주함수를 f2으로 했을 때의 주표본 추정치와 분산
```

```
mean( g(u) / f2(u) ) ; (integrate(gf2, a, b)$value - I^2) / N
```

```
## [1] 1.075948
```

```
## [1] 6.482776e-05
```